

Documentación de Proceso: Análisis de Datos de Diabetes

Este documento detalla el flujo de trabajo de limpieza, transformación y enriquecimiento de datos aplicado al dataset principal `df_main`, con el objetivo de preparar la información para un análisis exploratorio (EDA) robusto y eficiente.

1. Limpieza Inicial y Gestión de Nulos

Al explorar el dataset principal, se identificó que los valores faltantes estaban representados por el carácter `?`.

- **Estandarización:** Se convirtieron todos los valores `?` a `NaN` para permitir un análisis estadístico real del estado del dataset.
 - **Gestión de Variables Categóricas:** Para conservar la utilidad de las columnas categóricas, se renombraron los valores nulos o desconocidos como `Other` en las siguientes variables:
 - **Race:** Valores `?` asignados a `Other`.
 - **Gender:** Valores `Unknown/Invalid` asignados a `Other`.
 - **Payer_code** y **Medical_speciality:** Valores `?` asignados a `Other`.
 - **Eliminación de Columnas de Baja Densidad:** Se detectó que las columnas `weight` (peso), `A1Cresult` (azúcar en sangre) y `max_glu_serum` (glucosa máxima) tenían un **90% de valores nulos**. Al no ser recuperables, se eliminaron para evitar sesgos.
-

2. Desafío Técnico: Estandarización CIE-9

Uno de los puntos más críticos y desafiantes del proceso fue el tratamiento de las columnas de diagnóstico (`diag_1`, `diag_2`, `diag_3`), las cuales utilizan la **Clasificación Internacional de Enfermedades (CIE-9)**.

- **Estrategia:** Se realizó una agrupación basada en los códigos médicos para identificar específicamente casos de diabetes frente a otras patologías.
 - **Resultado:** Se generaron tres nuevas columnas: `diag_1_group`, `diag_2_group` y `diag_3_group`.
 - **Optimización:** Tras el agrupamiento, se eliminaron las columnas originales con códigos crudos para mejorar la legibilidad y reducir el peso del dataset.
-

3. Estandarización de Tratamientos y Medicación

El dataset original presentaba 23 columnas individuales de medicamentos, lo que hacía el análisis tedioso. Se simplificó la lógica mediante ingeniería de características:

1. **Conteo de Cambios (`med_change_count`):** Se creó una función para recorrer las 23 columnas y contar cuántas veces aparecían los términos `up` (aumento) o `down` (descenso) por paciente.
2. **Estado del Tratamiento (`treatment_status`):** Basado en el conteo anterior, se clasificó la estabilidad del tratamiento:
 - **Stable:** 0 cambios.
 - **Low Instability:** 1 cambio.

- **High Instability:** >1 cambio.
3. **Simplificación:** Se eliminaron las 23 columnas de medicamentos y el contador temporal, manteniendo solo la columna de estado final.

4. Ingeniería de Atributos (Feature Engineering)

Reingresos (Readmission)

Se estandarizó la columna `readmitted` (valores original `<30`, `>30`, `no`) en una nueva variable llamada `readmitted_status` para facilitar la creación de gráficos descriptivos sobre reingreso temprano o tardío.

Edad Numérica (Age)

La columna `age` venía en rangos de texto (ej. `[10-20]`). Para permitir cálculos estadísticos (como la edad promedio):

- Se asignó el **punto medio** de cada rango (ej: `[10-20]` -> `15`).
- Se almacenó en `age_numeric` y se eliminó la columna de texto original.

Categorización de Estancia Hospitalaria

Se transformó `time_in_hospital` en una variable categórica `hospital_stay_type` según la duración de la internación:

Categoría	Días de Estancia
Ambulatory	1 - 2 días
Standard	3 - 4 días
Moderate	5 - 7 días
Prolonged	8+ días

Nota: Se conservó la columna numérica original para análisis de correlación en el EDA.

5. Enriquecimiento de Datos: `ids_mapping`

Se procesó el archivo complementario `ids_mapping` para traducir códigos numéricos en descripciones comprensibles.

1. **Normalización del Mapeo:** El archivo original estaba desordenado. Se aplicó un bucle `for` con detección de palabras clave (`discharge`, `source`) para asignar etiquetas de categoría correctamente.
2. **Limpieza de IDs:** Se eliminaron filas que repetían encabezados, se renombraron columnas a `id`, `description` y `category`, y se aseguraron formatos numéricos para el cruce.
3. **Merge Estratégico:** Se realizó un **Left Join** entre el dataset principal y el mapeo procesado para enriquecer:
 - `admission_type_id`
 - `discharge_disposition_id`
 - `admission_source_id`

4. **Post-procesamiento:** Los valores nulos resultantes del cruce se marcaron como **Unknown**.

❏ Conclusión del Proceso

Como paso final antes de la exportación, se eliminaron residuos del proceso de unión (**category_x**, **category_y**) y columnas redundantes.

- **Dataset Original:** 50 columnas.
- **Dataset Final:** 26 columnas optimizadas.

Resultado: El dataset está limpio, enriquecido y listo para realizar un análisis EDA profundo con datos estadísticamente significativos. 🚀